

# Langages et Automates

## Langages

Engel Lefaucieux

Prépas des INP

# Objectif de ce cours

- Apprendre à créer et manipuler un langage
  - Opérations sur les mots et les langages
- Langage régulier
  - Expression régulière
  - Critères de régularité

## Comment construit-on un langage ?

- Description extentionnelle :  $\{\text{mot}_1, \text{mot}_2, \text{mot}_3\}$
  - Description intentionnelle : "tous les mots qui..."
  - Description définitoire :  $\{xyz \mid z = yx\}$
  - Par opération sur des langages déjà définis
- une structure d'anneau pour les langages

# Plan

- 1 Construction et opérations sur les langages
- 2 Expressions régulières
- 3 Critères de régularité

# Outline

- 1 Construction et opérations sur les langages
- 2 Expressions régulières
- 3 Critères de régularité

# L'alphabet, une brique de base

Alphabet  $\Sigma$  : l'ensemble fini des éléments minimaux du langage

- Lettre :  $\Sigma = \{a, b, \dots, z\}$
- Playstation :  $\Sigma = \{haut, bas, gauche, droite, \square, \dots\}$
- $\Sigma = \{abc, a, tub\}$
- $\Sigma = \emptyset$

Pas de répétitions ni d'ordre :  $\{a, b, c, b\} = \{a, b, c\}$

# Mot = concaténation de symboles

On fixe un alphabet  $\Sigma$ ,

- Tout élément de  $\Sigma$  est un mot
- Concaténation : Si  $w$  et  $v$  sont des mots, alors  $w \cdot v$  est un mot
  - Associativité :  $w \cdot (v \cdot u) = (w \cdot v) \cdot u$
  - Non-commutativité :  $0 \cdot 1 \neq 1 \cdot 0$
- $\varepsilon$  représente le mot vide
  - $w \cdot \varepsilon = \varepsilon \cdot w = w$
- $w^n$  représente le mot  $\underbrace{w \cdot w \dots w \cdot w}_{n \text{ times}}$

Pour  $\Sigma = \{abc, a, tub\}$ ,  $a \cdot abc \cdot a \cdot tub$  est un mot

On omettra souvent le  $\cdot$  quand l'alphabet ne crée pas d'ambiguïté:

Pour  $\Sigma = \{a, b, c\}$ ,  $a \cdot b \cdot c \cdot b = abcb$

## Sous-mots et taille d'un mot

Si  $z = uvw$

- $u$  est un préfixe de  $z$
- $w$  est un suffixe de  $z$
- $u, v$  et  $w$  sont des facteurs de  $z$ .

Taille du mot  $z$

- Notée  $|z|$
- Nombre d'éléments dans  $z$
- $|a \cdot l \cdot e \cdot s \cdot t \cdot o \cdot r \cdot m| = 8$
- $|\varepsilon| = 0$
- $|z| = |u| + |v| + |w|$

Combien existe-t-il de mots de taille 2 sur l'alphabet  $\Sigma = \{a, b\}$  ?



## Exercice

### Lemma

*Deux mots  $u$  et  $v$  commutent s'ils sont puissances d'un même troisième, i.e., s'il existe un mot  $w$  et des entiers  $i, j$  tels que  $u = w^i$  et  $v = w^j$ .*

# Langages = Ensemble de mots

Tout ensemble de mots de  $\Sigma$  est un langage sur  $\Sigma$ .

Si  $L_1$  et  $L_2$  sont des langages, alors

- Union :  $L_1 \cup L_2$  est un langage
  - $\{a, b, c, ab\} \cup \{a, b, cd\} = \{a, b, c, ab, cd\}$
  - associative et commutative
- Intersection :  $L_1 \cap L_2$  est un langage
  - $\{a, b, c, ab\} \cap \{a, b, cd\} = \{a, b\}$
  - associative et commutative
- Différence :  $L_1 \setminus L_2$  est un langage
  - $\{a, b, c, ab\} \setminus \{a, b, cd\} = \{c, ab\}$
  - non-associative et non-commutative

## Autres opérations sur les langages

- concaténation :  $L_1 \cdot L_2$  est un langage
  - Tout mot de  $L_1$  concaténé à un mot de  $L_2$
  - $\{a, b, c, ab\} \cdot \{a, b, cd\} =$   
 $\{aa, ab, acd, ba, bb, bcd, ca, cb, ccd, aba, abb, abcd\}$
  - associative, non-commutative
- Puissance :  $L_1^n$  pour  $n$  entier est un langage
  - Correspond à  $\underbrace{L_1 \cdot L_1 \dots L_1 \cdot L_1}_{n \text{ times}}$

# Étoile de Kleene

$L^*$  est l'ensemble des mots obtenus par concaténation arbitraire

- $L^* = L^0 \cup L^1 \cup L^2 \cup L^3 \cup \dots$
- Aussi appelé itéré ou fermeture de  $L$
- $\{a, b\}^*$  est l'ensemble des mots écrits dans l'alphabet  $\{a, b\}$
- idempotent :  $(L^*)^* = L^*$
- $L^0 = \varepsilon \in L^*$
- $L^+ = L^* \setminus \{\varepsilon\}$

# Étoile de Kleene

$L^*$  est l'ensemble des mots obtenus par concaténation arbitraire

- $L^* = L^0 \cup L^1 \cup L^2 \cup L^3 \cup \dots$
- Aussi appelé itéré ou fermeture de  $L$
- $\{a, b\}^*$  est l'ensemble des mots écrits dans l'alphabet  $\{a, b\}$
- idempotent :  $(L^*)^* = L^*$
- $L^0 = \varepsilon \in L^*$
- $L^+ = L^* \setminus \{\varepsilon\}$

Est-ce que les mots suivants appartiennent au langage

$(\{a, b\} \cdot \{\varepsilon, r\})^*$

- $\varepsilon$
- $a$
- *babar*

# Notion d'induction

Soit  $L$  un langage satisfaisant

- $\varepsilon \in L$
- pour tout  $w \in L$  et  $a \in \Sigma$ ,  $wa \in L$ .

Que pouvez-vous dire sur  $L$  ?

# Notion d'induction

Soit  $L$  un langage satisfaisant

- $\varepsilon \in L$
- pour tout  $w \in L$  et  $a \in \Sigma$ ,  $wa \in L$ .

Que pouvez-vous dire sur  $L$  ?

## Lemma

*Soit  $P$  une propriété définie sur les mots de  $\Sigma^*$  et telle que*

- $P(\varepsilon)$
- *pour  $w \in \Sigma^*$  et  $a \in \Sigma$ , si  $P(w)$  alors  $P(wa)$ .*

*Alors  $P(w)$  pour tout  $w \in \Sigma^*$ .*

# Outline

- 1 Construction et opérations sur les langages
- 2 Expressions régulières
- 3 Critères de régularité



# Un formalisme pour générer certains langages

## Expressions régulières

- Parfois appelées expressions rationnelles
- Génère un langage "régulier"

Définition récursive sur un alphabet  $\Sigma = \{a, b\}$  :

- $\varepsilon$ ,  $a$  et  $b$  sont des expressions régulières pour  $\{\varepsilon\}$ ,  $\{a\}$  et  $\{b\}$
- Si  $r_1$  et  $r_2$  sont des expressions régulières générant  $L_1$  et  $L_2$ , alors
  - $r_1 \cdot r_2$  génère  $L_1 \cdot L_2$
  - $r_1 + r_2$  génère  $L_1 \cup L_2$
  - $r_1^*$  génère  $L_1^*$
  - $(r)$  est une expression régulière générant  $L_1$

→ les parenthèses servent à ordonner l'application des opérations

## Quelques exemples

Quelles langages pour les expressions régulières suivantes :

- $(a + b)^*$
- $a + b^*$
- $a(a)^*$
- $(a^*b^*)^*$
- $(a + ab^*a)^*$

Quelles expressions rationnelles pour les langages suivants :

- les mots n'ayant que des  $a$  ou que des  $b$
- $\{am, bm, an, cn\}$
- les mots de  $\{a, i, m, o, u\}^*$  ayant *miaou* en facteur
- $\{a^n b^n \mid n \in \mathbb{N}\}$ .

# Outline

- 1 Construction et opérations sur les langages
- 2 Expressions régulières
- 3 Critères de régularité

## Une règle d'or

Si des relations existent entre les exposants apparaissant dans la description du langage, alors celui-ci n'est pas régulier.

- $\{a^n b^n \mid n \in \mathbb{N}\}$
- $\{a^n b^m c^k \mid n, m, k \in \mathbb{N} \wedge k \geq n + m\}$

ne sont pas réguliers.

Plusieurs critères formels de non-régularité

- Théorème de Myhill-Nerode (complexe)
- Lemme de l'étoile (simple, mais ne marche pas tout le temps)

## Lemme de l'étoile

### Theorem

*Soit  $L$  un langage régulier. Il existe un entier  $N$  tel que tout mot  $w$  de  $L$  de longueur  $|w| \geq N$  possède une factorisation  $w = xyz$  avec  $0 < |y|$  telle que*

- ❶  $0 < |xy| \leq N$  et
- ❷  $xy^n z \in L$  pour tout entier  $n \geq 0$ .

## Lemme de l'étoile

### Theorem

*Soit  $L$  un langage régulier. Il existe un entier  $N$  tel que tout mot  $w$  de  $L$  de longueur  $|w| \geq N$  possède une factorisation  $w = xyz$  avec  $0 < |y|$  telle que*

- ❶  $0 < |xy| \leq N$  et
- ❷  $xy^n z \in L$  pour tout entier  $n \geq 0$ .

Quid de  $\{a^n b^n \mid n \in \mathbb{N}\}$  ?

## Exercice

Les langages suivants sont-ils réguliers ?

- $\{a^n \mid n \text{ est un nombre premier}\}$
- $\{a^n b^m \mid n \neq m\}$
- Le langage des palindromes
- $(ab)^* \cap \{w \mid |w|_a = |w|_b\}$
- $ab(a + b)^* \cap \{w \mid |w|_a = |w|_b\}$